

Université Lyon 2, Lyon 3, ENSIB, ENS Lyon

Origine, circularité et transformation des motifs naturalistes

Mémoire présenté par Morgan RICHARD

Année universitaire 2025–2026

Remerciements

Je tiens à remercier...

Résumé

Ce mémoire porte sur...

Table des matières

Remerciements	i
Résumé	ii
Introduction	1
1 Topic modeling sur les romans d'Émile Zola	2
1.1 Présentation de la méthode	2
1.2 Présentation du corpus d'étude	3
1.2.1 Choix du corpus	3
1.2.2 Préparation des données brutes en données propres	5
1.2.3 Préparation du corpus pour l'analyse thématique	6
1.2.4 Statistiques descriptives du corpus	8
1.2.5 Lemmatisation du corpus de Zola	11
1.3 Analyse avec la NMF et K-means	13
1.3.1 La méthode NMF	13
1.3.2 La méthode K-means	18
2 Nettoyage des romans et insertion de ces derniers dans la base de données	22
2.1 Reflexion sur le stockage des données	22
2.2 Nettoyage des textes	22
2.3 Création de la base de données	23
2.4 Création des informations pour la base de données	26
Annexe technique : code	28
0.1 Le code suivant présente le script Python utilisé pour nettoyer les textes extraits des fichiers EPUB après leur conversion au format .txt	28

Introduction

Chapitre 1

Topic modeling sur les romans d'Émile Zola

1.1 Présentation de la méthode

Émile Zola, l'un des écrivains majeurs du XIX^e siècle, est connu pour ses romans naturalistes, dans lesquels il explore les dimensions sociales, économiques et psychologiques de la vie humaine. Son œuvre romanesque constitue ainsi un corpus particulièrement riche pour l'analyse des thèmes récurrents, des milieux sociaux et des motifs narratifs.

Dans cette étude, nous examinons les thèmes présents dans les romans de Zola afin de déterminer dans quelle mesure certains motifs apparaissent de manière transversale dans son œuvre. Pour cela, nous mobilisons des méthodes d'analyse textuelle non supervisées, capables d'identifier des regroupements lexicaux à partir des textes eux-mêmes.

La question centrale de cette étude est donc la suivante : dans quelle mesure des méthodes non supervisées comme la NMF et K-means permettent-elles de faire apparaître des structures thématiques récurrentes dans l'œuvre romanesque de Zola ?

L'objectif est de vérifier si les regroupements produits automatiquement correspondent à des motifs interprétables dans le cadre d'une analyse littéraire. Il ne s'agit donc pas de remplacer la lecture critique des textes, mais d'utiliser les outils du traitement automatique du langage comme un moyen d'explorer un corpus littéraire volumineux.

Ce travail constitue le premier volet d'une série d'analyses portant sur des corpus de textes littéraires issus d'auteurs naturalistes et non naturalistes. Il sert à la fois de cas d'étude méthodologique et de base pour de futures comparaisons entre différents ensembles d'œuvres.

Deux méthodes d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola :

- la NMF (Non-negative Matrix Factorization)¹ : une technique de réduction de dimensionnalité qui permet d'extraire des topics à partir d'un corpus de textes ;
- K-means : une méthode de clustering qui permet de regrouper les segments textuels en fonction de leur proximité lexicale.

Ces méthodes seront expliquées dans les sections suivantes, avant la présentation des résultats de l'analyse thématique des romans de Zola.

Dans cette étude, le terme *topic* désigne un regroupement lexical produit par le modèle NMF, tandis que le terme *cluster* désigne un groupe de segments obtenu par K-means. Le terme *thème* est réservé à l'interprétation qualitative de ces regroupements. Cette précision terminologique est importante pour éviter toute confusion entre les différentes étapes de l'analyse.

1.2 Présentation du corpus d'étude

1.2.1 Choix du corpus

Cette étude porte sur un corpus composé exclusivement de romans d'Émile Zola. Le choix a été fait de ne pas inclure les nouvelles, les textes journalistiques ni les essais, afin de conserver un ensemble relativement homogène du point de vue générique. Les romans offrent en effet une matière textuelle plus longue et plus développée, ce qui permet d'observer plus finement les thèmes récurrents, les milieux sociaux et les motifs narratifs présents dans l'œuvre de Zola.

L'exclusion des nouvelles répond également à une contrainte méthodologique. Ces textes sont généralement plus courts que les romans et leur intégration aurait pu créer un déséquilibre dans le corpus. Dans le cadre d'une analyse thématique fondée sur des segments textuels, les différences importantes de longueur entre les œuvres peuvent influencer la représentation des thèmes. Limiter le corpus aux romans permet donc de réduire cet effet et de travailler sur un ensemble plus comparable.

Le corpus comprend les œuvres suivantes :

TABLE 1.1 – Corpus des œuvres de Zola utilisées dans l'analyse

Date	Titre	Fichier
1865	<i>La confession de Claude</i>	1865_La_confession_de_Claude._clean.txt
1866	<i>Le vœu d'une morte</i>	1866_Le_voeu_d_une_morte._clean.txt
1867	<i>Les mystères de Marseille</i>	1867_Les_mysteres_de_Marseille._clean.txt

1. N. Gillis, *Nonnegative Matrix Factorization*, Society for Industrial and Applied Mathematics, coll. « Data Science », 2020.

Date	Titre	Fichier
1867	<i>Thérèse Raquin</i>	1867_Therese_Raquin._clean.txt
1868	<i>Madeleine Féral</i>	1868_Madeleine_Ferat._clean.txt
1871	<i>La fortune des Rougon</i>	1871_1_La_fortune_des_Rougon._clean.txt
1872	<i>La curée</i>	1871_2_La_curee._clean.txt
1873	<i>Le ventre de Paris</i>	1873_3_Le_ventre_de_Paris._clean.txt
1874	<i>La conquête de Plassans</i>	1874_4_La_conquete_de_Plassans._clean.txt
1875	<i>La faute de l'abbé Mouret</i>	1875_5_La_faute_de_l_abbe_Mouret._clean.txt
1876	<i>Son Excellence Eugène Rougon</i>	1876_6_Son_Excellence_Eugene_Rougon._clean.txt
1877	<i>L'assommoir</i>	1877_7_L_assommoir._clean.txt
1878	<i>Une page d'amour</i>	1878_8_Une_page_d_amour._clean.txt
1880	<i>Nana</i>	1880_9_Nana._clean.txt
1882	<i>Pot-Bouille</i>	1882_10_Pot-bouille._clean.txt
1883	<i>Au Bonheur des dames</i>	1883_11_Au_Bonheur_des_dames._clean.txt
1884	<i>La joie de vivre</i>	1884_12_La_joye_de_vivre._clean.txt
1885	<i>Germinal</i>	1885_13_Germinal._clean.txt
1886	<i>L'œuvre</i>	1886_14_L_oeuvre._clean.txt
1887	<i>La terre</i>	1887_15_La_terre._clean.txt
1888	<i>Le rêve</i>	1888_16_Le_reve._clean.txt
1890	<i>La bête humaine</i>	1890_17_La_bete_humaine._clean.txt
1891	<i>L'argent</i>	1891_18_L_argent._clean.txt
1892	<i>La débâcle</i>	1892_19_La_debacle._clean.txt
1893	<i>Le docteur Pascal</i>	1893_20_Le_docteur_Pascal._clean.txt
1894	<i>Lourdes</i>	1894_1_Lourdes._clean.txt
1896	<i>Rome</i>	1896_2_Rome._clean.txt
1898	<i>Paris</i>	1898_3_Paris._clean.txt
1899	<i>Fécondité</i>	1899_1_Fecondite._clean.txt
1901	<i>Travail</i>	1901_2_Travail._clean.txt
1903	<i>Vérité</i>	1903_3_Verite._clean.txt

Le corpus est composé de 31 romans, qui couvrent les principales périodes de la production romanesque de Zola. Il comprend :

- 5 romans antérieurs au cycle des *Rougon-Macquart* ;
- 20 romans appartenant au cycle des *Rougon-Macquart* ;
- 3 romans du cycle des *Trois Villes* ;
- 3 romans publiés du cycle des *Quatre Évangiles*.

Pour ce qui est des *Quatre Évangiles*, *Vérité* paraît à titre posthume. *Justice* ne paraîtra jamais, l'ouvrage étant resté à l'état d'ébauche au moment de la mort de l'écrivain.

Ce corpus permet donc de couvrir une large période de la carrière de Zola, depuis ses premiers romans jusqu'à ses dernières œuvres. Cette amplitude chronologique est importante pour l'analyse, car elle permet d'observer non seulement les thèmes récurrents de l'œuvre romanesque, mais aussi leur possible évolution au fil du temps².

1.2.2 Préparation des données brutes en données propres

Les romans au format `.txt` correspondent à des versions nettoyées, c'est-à-dire à des textes dont les éléments non textuels ont été supprimés. Ces éléments comprennent notamment les titres, les chapitres, les notes de bas de page et d'autres informations éditoriales qui pourraient perturber l'analyse. Ce nettoyage permet d'obtenir une représentation plus précise des thèmes présents dans les romans.

De plus, le choix a été fait de conserver une seule phrase par ligne. Ce format facilite l'analyse textuelle, notamment pour les méthodes de la NMF et de K-means, qui nécessitent une structure de données homogène pour fonctionner correctement.

Cette logique de formatage a également été appliquée en prévision des analyses futures. Les romans issus de prochains traitements pourront ainsi être intégrés de manière cohérente au corpus. Ce choix permet de limiter les différences de structure entre les fichiers et d'obtenir un format homogène pour l'analyse sans trop complexifier le processus de préparation des données.

TABLE 1.2 – Nombre de tokens par roman dans l'ordre chronologique

Titre du roman	Nombre de tokens
<i>La confession de Claude</i>	47253
<i>Le vœu d'une morte</i>	38722
<i>Les mystères de Marseille</i>	125253
<i>Thérèse Raquin</i>	66363
<i>Madeleine Féral</i>	97318
<i>La fortune des Rougon</i>	116685
<i>La curée</i>	105120
<i>Le ventre de Paris</i>	110442
<i>La conquête de Plassans</i>	113245
<i>La faute de l'abbé Mouret</i>	114667
<i>Son Excellence Eugène Rougon</i>	126186

2. En vue d'une éventuelle analyse ultérieure par dynamic topic modeling sur ce même corpus.

Titre du roman	Nombre de tokens
<i>L'assommoir</i>	158340
<i>Une page d'amour</i>	102185
<i>Nana</i>	141573
<i>Pot-Bouille</i>	134844
<i>Au Bonheur des dames</i>	147521
<i>La joie de vivre</i>	117255
<i>Germinal</i>	164473
<i>L'œuvre</i>	130613
<i>La terre</i>	163687
<i>Le rêve</i>	66379
<i>La bête humaine</i>	125418
<i>L'argent</i>	143010
<i>La débâcle</i>	187046
<i>Le docteur Pascal</i>	112713
<i>Lourdes</i>	173511
<i>Rome</i>	233958
<i>Paris</i>	177389
<i>Fécondité</i>	220131
<i>Travail</i>	198712
<i>Vérité</i>	223274

Le tableau fournit une description quantitative du corpus en indiquant, pour chaque roman, le nombre de tokens obtenus après nettoyage. Les œuvres sont présentées dans l'ordre chronologique, ce qui permet d'observer l'évolution du volume textuel au sein de la production romanesque de Zola. Les écarts sont importants entre les romans courts du début de carrière, comme *Le vœu d'une morte*, et les œuvres plus volumineuses de la fin de carrière, notamment *Rome*, *Fécondité*, *Travail* et *Vérité*.

Cette information est importante pour l'interprétation des résultats, car la longueur des textes peut avoir un effet sur la représentation des thèmes. Un roman plus long fournit mécaniquement davantage d'occurrences lexicales et davantage de segments analysables. La segmentation en paquets de phrases vise donc à produire des unités d'analyse plus comparables, tout en conservant suffisamment de contexte pour identifier les thèmes dominants.

1.2.3 Préparation du corpus pour l'analyse thématique

Pour préparer le corpus à l'analyse thématique, nous avons adopté une procédure visant à produire des unités textuelles comparables et exploitables par les modèles.

Les romans ont été segmentés en paquets de phrases³. Chaque paquet est composé de 40 phrases. Cette taille a été retenue car elle offre un compromis entre deux exigences : conserver suffisamment de contexte pour identifier les thèmes présents dans les romans, tout en permettant une analyse plus fine qu'un découpage à l'échelle du chapitre ou de l'œuvre entière.

Ce choix reste toutefois méthodologique et partiellement arbitraire. Plusieurs tailles de paquets ont été testées⁴. Les paquets de 40 phrases ont été retenus, car ils produisaient les résultats les plus cohérents et les plus interprétables parmi les configurations testées. Ce choix n'est donc pas parfait, mais il constitue le meilleur compromis observé dans le cadre de cette analyse.

D'autres modes de segmentation ont également été envisagés, notamment un découpage par chapitre ou par paragraphe. Le découpage par chapitre a été écarté, car les chapitres ne constituent pas des unités suffisamment homogènes en longueur et en contenu. Certains chapitres sont très courts, tandis que d'autres sont beaucoup plus longs, ce qui rend la comparaison entre unités d'analyse plus difficile.

Le découpage par paragraphe a également été étudié, mais il posait plusieurs problèmes. D'abord, les paragraphes varient fortement en longueur : certains sont très courts, tandis que d'autres sont beaucoup plus développés. Cette difficulté pourrait être partiellement corrigée par un filtrage des paragraphes trop courts ou trop longs, mais cela introduirait une étape supplémentaire et rendrait le traitement moins homogène.

Ensuite, l'architecture matérielle des textes n'est pas toujours conservée de manière fiable dans les fichiers disponibles. Certains romans ne présentent plus une mise en page avec des paragraphes clairement identifiables, en particulier lorsque les textes proviennent de formats différents, comme des fichiers `.txt`, `.pdf` ou `.epub`. Or, ce travail s'inscrit dans une perspective d'élargissement du corpus à d'autres romans et à d'autres sources textuelles. Dans ce contexte, la segmentation par phrase apparaît plus facilement généralisable à des formats hétérogènes.

Enfin, la structure interne des romans pose un dernier problème. Les dialogues peuvent être considérés comme des paragraphes indépendants, ce qui produit parfois des unités d'analyse très courtes, composées de seulement quelques mots. Là encore, un filtrage serait possible, mais il complexifierait le protocole et risquerait d'introduire des différences de traitement entre les textes.

Pour ces raisons, le découpage en paquets de 40 phrases a été retenu. Il permet de produire des unités d'analyse relativement homogènes, applicables à l'ensemble du corpus, tout en conservant une quantité suffisante de contexte pour l'analyse thématique.

3. Le code pour segmenter les romans est disponible en annexe, dans la section « Segmentation du corpus ».

4. Différents essais ont été réalisés avec des paquets de 10, 50, 70 et 100 phrases.

1.2.4 Statistiques descriptives du corpus

TABLE 1.3 – Nombre de paquets de phrases par roman

Titre du roman	Nombre de paquets
<i>La confession de Claude</i>	65
<i>Le vœu d'une morte</i>	60
<i>Les mystères de Marseille</i>	184
<i>Thérèse Raquin</i>	80
<i>Madeleine Férat</i>	124
<i>La fortune des Rougon</i>	154
<i>La curée</i>	123
<i>Le ventre de Paris</i>	136
<i>La conquête de Plassans</i>	165
<i>La faute de l'abbé Mouret</i>	171
<i>Son Excellence Eugène Rougon</i>	191
<i>L'assommoir</i>	228
<i>Une page d'amour</i>	166
<i>Nana</i>	225
<i>Pot-Bouille</i>	207
<i>Au Bonheur des dames</i>	198
<i>La joie de vivre</i>	164
<i>Germinal</i>	225
<i>L'œuvre</i>	163
<i>La terre</i>	222
<i>Le rêve</i>	82
<i>La bête humaine</i>	154
<i>L'argent</i>	155
<i>La débâcle</i>	221
<i>Le docteur Pascal</i>	135
<i>Lourdes</i>	198
<i>Rome</i>	231
<i>Paris</i>	206
<i>Fécondité</i>	259
<i>Travail</i>	208
<i>Vérité</i>	227

Ce tableau indique le nombre de paquets de phrases obtenus pour chaque roman après segmentation du corpus. Les écarts observés reflètent principalement les différences

de longueur entre les œuvres : les textes les plus courts, comme *Le vœu d'une morte* ou *La confession de Claude*, produisent peu de paquets, tandis que les romans plus volumineux, comme *Fécondité*, *Rome* ou *L'assommoir*, en produisent davantage.

Analyse des statistiques descriptives du nombre de paquets par roman

TABLE 1.4 – Statistiques descriptives du nombre de paquets par roman

Indicateur	Valeur
Nombre de romans	31
Moyenne	171.84
Écart-type	52.40
Minimum	60
Premier quartile	145
Médiane	171
Troisième quartile	214.5
Maximum	259

Les statistiques descriptives du nombre de paquets par roman permettent d'évaluer la structure quantitative du corpus après segmentation. Le corpus comprend 31 romans, avec une moyenne d'environ 172 paquets de phrases par œuvre. La médiane, située à 171 paquets, est très proche de cette moyenne. Cette proximité indique que la distribution générale du nombre de paquets n'est pas fortement asymétrique : la majorité des romans se situe autour d'un volume intermédiaire, même si certains textes s'écartent nettement de cette tendance.

L'écart-type, d'environ 52 paquets, montre toutefois une dispersion importante autour de la moyenne. Cette variation s'explique principalement par les différences de longueur entre les romans. Les œuvres les plus courtes, comme *Le vœu d'une morte*, produisent seulement 60 paquets, tandis que les textes les plus longs, comme *Fécondité*, atteignent 259 paquets. L'écart entre le minimum et le maximum est donc notable, puisqu'il existe presque un rapport de un à quatre entre le roman le moins segmenté et le roman le plus segmenté.

Les quartiles permettent de préciser cette répartition. Le premier quartile, situé à 145 paquets, indique qu'un quart des romans contient 145 paquets ou moins. Le troisième quartile, situé à 214,5 paquets, indique qu'environ trois quarts des romans restent sous ce seuil. La moitié centrale du corpus se situe donc entre 145 et 214,5 paquets, ce qui montre que la majorité des œuvres conserve une taille relativement comparable après segmentation. Les valeurs extrêmes ne remettent donc pas en cause l'homogénéité

générale du corpus, mais elles doivent être prises en compte dans l'interprétation des résultats.

Le coefficient de variation est d'environ 30 %, puisqu'il correspond au rapport entre l'écart-type et la moyenne. Cette valeur signale une variabilité modérée : les romans ne sont pas tous de taille équivalente, mais les écarts restent attendus pour un corpus littéraire composé d'œuvres publiées à des périodes différentes et appartenant à plusieurs cycles romanesques. Cette dispersion est donc méthodologiquement acceptable, à condition de garder à l'esprit que les romans les plus longs fournissent davantage d'unités d'analyse.

Cette information est importante pour l'analyse thématique. Chaque paquet de phrases constitue une unité soumise aux méthodes de topic modeling. Par conséquent, un roman plus long contribue mécaniquement à un plus grand nombre d'observations qu'un roman court. Les thèmes présents dans les romans volumineux peuvent donc être davantage représentés dans les résultats globaux. La segmentation en paquets de 40 phrases permet néanmoins de réduire cet effet, car elle transforme les romans en unités textuelles comparables tout en conservant suffisamment de contexte pour identifier des thèmes cohérents.

Ainsi, ces statistiques montrent que le corpus présente un équilibre satisfaisant pour une analyse thématique. Les différences de taille entre les romans existent, mais elles sont documentées et peuvent être intégrées à l'interprétation des résultats. Cette étape descriptive permet donc de mieux contrôler les effets liés à la longueur des œuvres avant l'application des méthodes de NMF et de K-means.

Analyse des statistiques descriptives du nombre de mots par paquet

TABLE 1.5 – Statistiques descriptives du nombre de mots par paquet

Indicateur	Valeur
Nombre de paquets	5327
Moyenne	785.30
Écart-type	212.13
Minimum	42
Premier quartile	636
Médiane	753
Troisième quartile	902.5
Maximum	2944

Les statistiques descriptives du nombre de mots par paquet permettent d'évaluer la taille effective des unités textuelles utilisées pour l'analyse thématique. Le corpus

segmenté comprend 5327 paquets, avec une moyenne d'environ 785 mots par paquet. La médiane, située à 753 mots, est relativement proche de cette moyenne, ce qui indique que la majorité des paquets se situe autour d'un volume textuel comparable.

L'écart-type est d'environ 212 mots, ce qui traduit une dispersion modérée autour de la moyenne. Le coefficient de variation est d'environ 27 %, puisqu'il correspond au rapport entre l'écart-type et la moyenne. Cette valeur indique que les paquets ne sont pas parfaitement homogènes en longueur, mais que la variabilité reste acceptable pour une analyse thématique. Cette variation s'explique par le fait que les paquets sont construits à partir d'un nombre fixe de phrases, et non d'un nombre fixe de mots : selon le style, le rythme narratif ou la longueur syntaxique des phrases, deux paquets de 40 phrases peuvent contenir un nombre de mots assez différent.

Les quartiles permettent de préciser cette distribution. Un quart des paquets contient au maximum 636 mots, tandis que la moitié des paquets contient au maximum 753 mots. Le troisième quartile, situé à 902,5 mots, indique que 75 % des paquets ne dépassent pas environ 903 mots. Ainsi, la majorité des unités d'analyse se concentre dans une zone relativement stable, comprise approximativement entre 636 et 903 mots pour la moitié centrale du corpus. Cette concentration est favorable au topic modeling, car elle limite les écarts de taille entre les unités comparées.

Les valeurs extrêmes doivent toutefois être prises en compte. Le paquet le plus court contient seulement 42 mots, tandis que le plus long atteint 2944 mots. Ces deux valeurs indiquent la présence d'unités atypiques. Le paquet de 42 mots correspond probablement à une fin de roman ou à un segment résiduel composé de moins de phrases que les autres. À l'inverse, le paquet de 2944 mots peut provenir d'un passage composé de phrases particulièrement longues ou d'une segmentation imparfaite du texte source. Ces cas extrêmes peuvent influencer l'analyse, car un paquet très long contient davantage d'information lexicale et peut donc peser plus fortement dans la représentation des thèmes.

Dans l'ensemble, ces statistiques montrent que la segmentation en paquets de 40 phrases produit des unités textuelles globalement comparables. Malgré une variabilité réelle, la distribution reste suffisamment concentrée autour de la médiane pour permettre une analyse thématique cohérente. Il serait toutefois pertinent d'examiner les paquets extrêmes afin de vérifier s'ils correspondent à des cas normaux du corpus ou à des problèmes de segmentation.

1.2.5 Lemmatisation du corpus de Zola

Après avoir obtenu un corpus segmenté en paquets de phrases et relativement homogène en termes de nombre de mots, l'étape suivante de préparation des données a

consisté à effectuer une lemmatisation du corpus⁵.

Pour réaliser cette lemmatisation, nous avons utilisé la bibliothèque `spaCy` en Python, qui offre des outils performants pour le traitement automatique du langage. La lemmatisation permet de regrouper les différentes formes d'un même mot sous une seule forme de base : par exemple, les mots « manger », « mange » et « manges » sont tous réduits au lemme « manger ». Cette étape facilite l'identification des thèmes et contribue à réduire la dimensionnalité du corpus.

Comme pour la segmentation en paquets de phrases, plusieurs essais ont été réalisés avec la bibliothèque de lemmatisation `spaCy`.

Nous avons choisi d'utiliser le modèle `fr_core_news_lg` de `spaCy`, qui est un modèle de langue française de grande taille. Ce choix a été motivé par la richesse lexicale et la complexité syntaxique des romans de Zola, qui nécessitent un modèle capable de gérer une grande variété de formes linguistiques. Le modèle `fr_core_news_lg` a été retenu, car il offre une lemmatisation plus précise que des modèles plus légers⁶, ce qui est important pour l'identification des thèmes dans les textes littéraires.

Une liste de mots à exclure a été construite progressivement au cours de plusieurs itérations de prétraitement⁷. Elle résulte de l'observation conjointe des sorties de lemmatisation et de la matrice terme-document. L'objectif était d'identifier les formes lexicales très fréquentes dans le corpus, mais peu discriminantes pour l'analyse thématique.

Cette liste contient d'abord des mots-outils, tels que les pronoms personnels, les conjonctions, les déterminants et les prépositions. Ces termes structurent grammaticalement les phrases, mais ils ne permettent pas d'identifier les thèmes dominants des romans. Leur présence importante dans la matrice terme-document risquait donc de réduire la lisibilité des topics produits par la NMF.

La liste a également été enrichie par l'ajout de certains noms propres, notamment des noms de personnages récurrents dans les romans de Zola. Ces noms apparaissent fréquemment dans les textes, mais leur poids lexical tendait à orienter les topics vers des personnages plutôt que vers des thèmes plus généraux, comme le travail, la famille, la religion, l'argent ou les rapports sociaux. Leur exclusion permet donc de privilégier une interprétation thématique plutôt qu'une simple identification des protagonistes.

Ce filtrage relève d'un choix méthodologique empirique. Lors des premiers essais, plusieurs mots restaient fortement représentés dans les résultats malgré les paramètres appliqués au lemmatiseur et au vectoriseur. La liste d'exclusion a donc été ajustée à partir de l'examen des termes les plus fréquents et des premiers topics obtenus. Elle vise à améliorer la qualité interprétative de la matrice terme-document en conservant prioritairement les mots porteurs d'information thématique.

5. Code disponible en annexe, dans la section « Lemmatisation et filtrage lexical ».

6. Les modèles `fr_core_news_sm` et `fr_core_news_md` ont également été envisagés.

7. Elle est présente en annexe du document.

Une fonction applique le modèle **spaCy** à chaque segment du corpus afin d'en extraire une version lemmatisée et filtrée⁸. Pour chaque token, le lemme est d'abord converti en minuscules afin de normaliser les formes lexicales. La fonction exclut ensuite les mots vides, la ponctuation, les nombres, les espaces, ainsi que les lemmes trop courts ou présents dans la liste personnalisée de mots à retirer. Le filtrage conserve uniquement les noms et les adjectifs, car ces catégories grammaticales sont généralement les plus porteuses d'information thématique dans le cadre d'une analyse de topics. Le résultat final est une chaîne de caractères composée des lemmes retenus, qui peut ensuite être utilisée pour construire la matrice terme-document.

À l'issue de cette préparation, chaque roman est représenté par un ensemble de segments lemmatisés et filtrés. Ces segments constituent les unités d'analyse utilisées pour les deux méthodes de modélisation thématique présentées dans la section suivante.

1.3 Analyse avec la NMF et K-means

Comme mentionné précédemment, deux méthodes d'analyse ont été utilisées pour identifier les thèmes dans les romans de Zola : la NMF (Non-negative Matrix Factorization) et K-means. Cette section présente ces deux méthodes et expose les choix retenus pour leur application au corpus préparé.

1.3.1 La méthode NMF

La NMF est une technique de réduction de dimensionnalité qui permet d'extraire des thèmes à partir d'un corpus de textes. Elle fonctionne en factorisant la matrice terme-document en deux matrices non négatives : une matrice de thèmes et une matrice de poids. La matrice de thèmes contient les mots les plus représentatifs de chaque thème, tandis que la matrice de poids indique l'importance de chaque thème dans chaque document ou paquet de phrases.

La présentation commence par la NMF, avant d'aborder le clustering par K-means comme méthode complémentaire.

Après la préparation du corpus, la segmentation en paquets de phrases et la lemmatisation des textes, l'étape suivante consiste à appliquer une méthode de modélisation thématique. L'objectif est d'identifier automatiquement les grands thèmes présents dans les romans de Zola, à partir des termes les plus représentatifs de chaque segment textuel.

Dans cette analyse, la méthode retenue est la NMF, pour *Non-negative Matrix Factorization*. Cette méthode permet de décomposer une matrice terme-document en deux matrices plus simples : une matrice associant les segments de texte aux topics,

8. Fonction en Python disponible en annexe du document.

et une matrice associant les topics aux termes les plus caractéristiques. La NMF est particulièrement adaptée à ce type d'analyse, car elle produit des résultats relativement interprétables : chaque topic peut être compris comme un ensemble de mots fortement associés entre eux.

Création de la matrice terme-document

La première étape consiste à transformer les textes lemmatisés en une représentation numérique exploitable par le modèle. Pour cela, une matrice terme-document a été construite à l'aide d'une pondération TF-IDF⁹. Cette méthode permet de donner un poids plus important aux termes caractéristiques d'un segment, tout en réduisant l'influence des mots trop fréquents dans l'ensemble du corpus.

Les paramètres `min_df` et `max_df` jouent un rôle important dans la qualité de la matrice obtenue. Le paramètre `min_df=3` permet d'exclure les mots qui apparaissent dans moins de trois segments. Ces mots sont généralement trop rares pour contribuer efficacement à l'identification de thèmes récurrents. À l'inverse, le paramètre `max_df=0.8` exclut les termes présents dans plus de 80 % des segments, car ils sont trop fréquents pour être réellement discriminants¹⁰.

Ce choix relève d'un arbitrage méthodologique. Plusieurs combinaisons ont été testées, puis évaluées à partir de la qualité des mots conservés et de la cohérence des premiers topics obtenus. L'objectif n'était donc pas seulement de réduire la taille de la matrice, mais surtout de conserver les termes les plus utiles pour l'analyse thématique. La matrice finale sert ensuite de base à l'application du modèle NMF.

Choix du nombre de topics

Le choix du nombre de topics constitue une étape importante dans une analyse par NMF. Un nombre trop faible de topics risque de produire des catégories trop générales, dans lesquelles plusieurs thèmes distincts se trouvent regroupés. À l'inverse, un nombre trop élevé peut conduire à une fragmentation excessive des résultats, avec des topics trop proches les uns des autres ou difficiles à interpréter.

Afin d'orienter ce choix, une méthode du coude a d'abord été utilisée¹¹. Cette méthode consiste à entraîner plusieurs modèles NMF avec différents nombres de topics, puis à observer l'évolution de l'erreur de reconstruction. L'objectif est d'identifier un éventuel seuil à partir duquel l'ajout de nouveaux topics n'améliore plus fortement la qualité de reconstruction du modèle.

9. Utilisée via la bibliothèque `scikit-learn`.

10. Le vectoriseur est disponible en annexe.

11. Code visible en annexe.




FIGURE 1.1 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 2 et 40 topics

La première visualisation présente l'évolution de l'erreur de reconstruction pour un nombre de topics compris entre 2 et 40. On observe une diminution régulière de l'erreur lorsque le nombre de topics augmente. Cette baisse est attendue : plus le modèle dispose de topics, plus il peut reconstruire finement la matrice terme-document. Cependant, la courbe ne présente pas de rupture nette permettant d'identifier un coude évident. Le critère quantitatif ne suffit donc pas, à lui seul, à déterminer un nombre optimal de topics.

Une seconde visualisation a été produite en resserrant l'observation sur une zone plus restreinte, comprise entre 20 et 39 topics. Ce zoom permet d'examiner plus précisément la partie de la courbe dans laquelle plusieurs valeurs candidates pouvaient être envisagées.




FIGURE 1.2 – Méthode du coude pour le choix du nombre de topics dans la NMF, entre 20 et 39 topics

Ce second graphique confirme l’absence de seuil clairement marqué. L’erreur de reconstruction continue de diminuer de manière progressive, sans stabilisation brutale ni changement de pente suffisamment net pour imposer une valeur unique. Le choix du nombre de topics ne peut donc pas reposer uniquement sur la méthode du coude.

Le choix final a ainsi été complété par une analyse qualitative des résultats. Plusieurs valeurs ont été testées, notamment 10, 15, 20, 30 et 35 topics. Les modèles obtenus ont été comparés à partir des mots caractéristiques de chaque topic, de leur cohérence interne et de leur capacité à correspondre à des thèmes interprétables dans l’œuvre de Zola. Dans cette perspective, le choix de 29 topics a été retenu comme un compromis entre précision, lisibilité et stabilité interprétative.

Ce choix a également été mis en relation avec l’analyse par K-means. Le nombre de clusters retenu pour K-means a été fixé à 29 afin de permettre une comparaison directe entre les deux méthodes. Cette seconde approche ne sert pas à prouver définitivement que 29 est le nombre optimal de topics, mais elle permet de vérifier si une structuration thématique comparable apparaît lorsque les segments sont regroupés selon une logique différente. Autrement dit, K-means joue ici un rôle de validation complémentaire : si certains motifs apparaissent à la fois dans les topics NMF et dans les clusters K-means, cela renforce leur pertinence pour l’analyse du corpus.

Paramétrage du modèle NMF

Après plusieurs essais, le modèle final a été construit avec 29 topics. Cette valeur a été retenue, car elle permettait d’obtenir un niveau de détail suffisant, sans produire

une fragmentation trop importante des thèmes ni introduire trop de bruit. Les topics obtenus correspondent à des ensembles thématiques distincts, comme le monde ouvrier, la religion, la famille, la finance, la guerre, le commerce, la médecine ou encore l'espace domestique, comme nous le verrons dans la section consacrée aux résultats.

Le paramètre `n_components=29` correspond au nombre de topics recherchés. Le paramètre `random_state=42` permet d'assurer la reproductibilité des résultats. L'initialisation `nndsvda`¹² est adaptée à la NMF, car elle fournit une initialisation stable à partir de la structure de la matrice. Le solveur `cd`, pour *coordinate descent*, est utilisé pour optimiser la factorisation.

La matrice **W** contient les poids des topics pour chaque segment du corpus. Autrement dit, elle indique dans quelle mesure chaque segment est associé à chacun des 29 topics. La matrice **H**, quant à elle, contient les poids des mots pour chaque topic. Elle permet donc d'identifier les termes les plus représentatifs de chaque thème.

Limites de l'approche

L'utilisation de la NMF présente plusieurs avantages, notamment sa lisibilité et sa capacité à produire des topics relativement interprétables. Cependant, cette méthode comporte aussi des limites. Le choix du nombre de topics reste en partie subjectif, surtout lorsque la méthode du coude ne permet pas d'identifier une valeur optimale claire. Dans cette analyse, le choix de 29 topics repose donc sur un compromis entre précision, lisibilité et cohérence interprétative. La validation humaine des résultats est donc essentielle pour s'assurer que les topics produits correspondent à des thèmes réels et pertinents dans l'œuvre de Zola.

De plus, les noms attribués aux topics résultent d'une interprétation humaine. Deux personnes pourraient parfois proposer des intitulés légèrement différents pour un même groupe de mots. Il est donc important de considérer ces noms comme des outils d'analyse, et non comme des catégories fixes ou définitives. Cette subjectivité ne remet pas en cause la validité de l'analyse, mais elle souligne l'importance d'une approche critique et réflexive dans l'interprétation des résultats.

Enfin, les résultats dépendent fortement des choix effectués en amont : nettoyage du texte, lemmatisation, liste de mots à exclure, taille des segments, paramètres du vecteur et nombre de topics. La modélisation thématique ne doit donc pas être comprise comme une méthode entièrement automatique, mais comme un processus exploratoire qui combine traitement statistique et interprétation qualitative avec validation humaine à chaque étape.

12. L'initialisation `nndsvda` correspond à une variante de NNDSVD dans laquelle les zéros sont remplacés par la moyenne de la matrice. Voir la documentation de `scikit-learn`.

Bilan méthodologique

Cette étape de modélisation par NMF permet d’obtenir une première cartographie thématique du corpus romanesque de Zola. Elle fournit une base quantitative pour observer des régularités lexicales qui seront ensuite interprétées dans la section consacrée aux résultats.

La NMF constitue donc un outil pertinent pour explorer les thèmes récurrents dans un corpus littéraire volumineux. Elle ne remplace pas l’analyse littéraire, mais elle permet de faire apparaître des régularités lexicales et thématiques qui peuvent ensuite être interprétées plus finement. Dans le cadre de cette étude, elle sert à établir une base quantitative pour l’analyse des thèmes présents dans les romans de Zola.

1.3.2 La méthode K-means

Après l’application de la NMF, une seconde méthode a été utilisée afin de compléter l’analyse thématique du corpus : le clustering par K-means. Contrairement à la NMF, qui cherche à décomposer la matrice terme-document en topics latents, K-means vise à regrouper les segments textuels en ensembles homogènes à partir de leur proximité lexicale. L’objectif n’est donc pas exactement le même : la NMF permet d’identifier des thèmes sous forme de combinaisons de mots, tandis que K-means permet de regrouper les paquets de phrases qui présentent des profils lexicaux similaires.

Cette seconde méthode a été utilisée comme un outil complémentaire de comparaison et de validation. Elle permet de vérifier si les regroupements produits par la NMF correspondent également à des ensembles cohérents lorsque l’on applique une méthode de clustering non supervisée. Dans le cadre de cette analyse, chaque paquet de phrases constitue une unité d’observation, représentée numériquement par une matrice TF-IDF. Les clusters obtenus correspondent donc à des groupes de segments partageant des termes caractéristiques.

Préparation de la matrice TF-IDF

Comme pour la NMF, la première étape consiste à transformer les textes lemmatisés en une représentation numérique. La matrice utilisée pour le K-means est construite à partir des segments lemmatisés du corpus. Le même type de vectorisation TF-IDF et les mêmes paramètres ont été conservés afin d’assurer une cohérence méthodologique entre les deux approches¹³.

Ce choix permet de travailler sur une matrice plus lisible et plus pertinente pour le clustering. Le but n’est pas seulement de réduire le nombre de dimensions, mais aussi de conserver les mots qui participent réellement à la différenciation des segments. Cette

13. Voir la section consacrée à la préparation de la matrice terme-document dans l’approche NMF.

étape est essentielle, car la qualité des clusters dépend directement de la qualité de la représentation vectorielle utilisée.

Recherche du nombre de clusters

Le choix du nombre de clusters est une étape centrale dans l'utilisation de K-means. Un nombre trop faible de clusters risque de produire des groupes trop généraux, dans lesquels plusieurs thèmes différents seraient mélangés. À l'inverse, un nombre trop élevé peut produire des groupes trop fragmentés, difficiles à interpréter ou très proches les uns des autres.

Afin d'orienter ce choix, plusieurs valeurs de k ont été testées. Pour chaque valeur comprise entre 2 et 40, un modèle K-means a été entraîné, puis évalué à l'aide du score de silhouette¹⁴.

Ce score mesure la qualité de la séparation entre les clusters : plus il est élevé, plus les segments sont proches des éléments de leur propre cluster et éloignés des autres groupes.

Une visualisation des scores de silhouette a ensuite été produite afin d'observer l'évolution de la qualité du clustering selon le nombre de clusters.




FIGURE 1.3 – Évolution du score de silhouette en fonction du nombre de clusters dans K-means

Dans cette analyse, le score de silhouette fournit une indication quantitative, mais il ne suffit pas à lui seul à déterminer le nombre de clusters à retenir. Comme pour la NMF, le choix final repose donc sur un compromis entre indicateurs statistiques, lisibilité des résultats et cohérence interprétative. Le nombre de 29 clusters a été retenu afin de

14. Peter J. Rousseeuw, « Silhouettes : A graphical aid to the interpretation and validation of cluster analysis », *Journal of Computational and Applied Mathematics*, vol. 20, 1er novembre 1987, p. 53–65.

permettre une comparaison directe avec les 29 topics issus de la NMF, tout en conservant un niveau de détail suffisant pour distinguer les principaux motifs thématiques du corpus. De plus, le score de silhouette reste relativement stable autour de cette valeur, ce qui indique que les clusters obtenus sont globalement cohérents.

Entraînement du modèle K-means

Le modèle K-means final a été entraîné avec 29 clusters. Le paramètre `random_state=42` permet d'assurer la reproductibilité des résultats, tandis que le paramètre `n_init=10` indique que l'algorithme est lancé plusieurs fois avec des initialisations différentes afin de retenir la meilleure solution.

Chaque segment du corpus reçoit ainsi un numéro de cluster après l'entraînement du modèle. L'ajout de + 1 permet de numéroter les clusters à partir de 1 plutôt qu'à partir de 0, ce qui rend les résultats plus lisibles dans les tableaux et les visualisations. Chaque paquet de phrases est donc associé à un groupe thématique déterminé par sa proximité avec les autres segments du corpus.

Limites de l'approche par K-means

L'utilisation de K-means présente plusieurs limites qu'il faut prendre en compte. Tout d'abord, la méthode impose une appartenance unique de chaque segment à un cluster. Or, dans un texte littéraire, un même passage peut contenir plusieurs thèmes simultanément. Un segment peut par exemple associer la famille, l'argent et la souffrance sociale, mais K-means l'attribue malgré tout à un seul groupe. Cette contrainte rend la méthode moins souple que la NMF pour représenter la complexité thématique des textes.

Ensuite, le choix du nombre de clusters reste en partie subjectif. Le score de silhouette fournit une indication utile, mais il ne suffit pas toujours à identifier une valeur optimale. Dans cette analyse, le choix de 29 clusters repose donc sur un arbitrage méthodologique : il permet de conserver un niveau de détail comparable à celui de la NMF, tout en produisant des catégories suffisamment interprétables.

Une autre limite concerne la sensibilité de K-means à la représentation vectorielle. Les clusters dépendent fortement de la matrice TF-IDF, des choix de lemmatisation, de la liste de mots exclus et des paramètres `min_df` et `max_df`. Une modification de ces choix peut modifier la structure des clusters obtenus, comme cela peut également être le cas avec la NMF. Les résultats doivent donc être compris comme une cartographie exploratoire du corpus, et non comme une classification définitive.

Enfin, comme pour la NMF, la nomination des clusters repose sur une interprétation humaine. Les intitulés attribués aux clusters et aux grandes familles de motifs sont construits à partir des mots les plus représentatifs et de l'observation des segments.

Cette étape qualitative est nécessaire pour donner du sens aux résultats, mais elle introduit aussi une part de subjectivité.

Bilan méthodologique

L'ajout d'une classification hiérarchique sur les centres des clusters permet également d'organiser les résultats en grandes familles de motifs. Cette étape rend l'analyse plus lisible, car elle permet de passer de 29 clusters détaillés à cinq ensembles thématiques plus généraux, qui seront interprétés dans la section consacrée aux résultats.

Après la présentation des deux méthodes, la section suivante expose les principaux résultats obtenus, d'abord pour la NMF, puis pour K-means.

Chapitre 2

Nettoyage des romans et insertion de ces derniers dans la basse de données

2.1 Reflexion sur le stockage des données

Après avoir récupéré un nombre conséquent de romans naturalistes et non naturaliste, il a fallu réfléchir à un moyen de les stocker quelque part. Pour cela, j'ai réfléchi à plusieurs idées pour procéder. Le choix c'est porté sur une base de données SQL avec comme interface PHP admin. Cette base de données à d'abord été remplie en local pour effectuer des tests et ensuite, une fois que tout fonctionnait correctement, j'ai pu extraire un fichier *Dumps* et l'importer dans PHP Admin.

2.2 Nettoyage des textes

Après avoir réfléchi à la manière de stocker les romans, il a fallu réfléchir à un moyen de les nettoyer. En effet, les romans contiennent beaucoup de caractères spéciaux qui ne sont pas utiles pour l'analyse, notamment les caractères de mise en forme, la pagination, les notes de bas de page, les chapitres ainsi que les prologues. En effet, les prologues sont souvent des textes qui ne sont pas écrits par l'auteur du roman et qui ne sont donc pas représentatifs de son style d'écriture.

Les romans naturalistes et non naturalistes sont issus de types de données différents. Il y a trois groupes de formats de données : les romans au format *.epub*, les romans au format *.pdf* et les romans au format *.txt*¹.

Pour ce qui est des textes au format *.epub*, j'ai utilisé le logiciel *Calibre*² pour les

1. Ici, les textes au format *.txt* sont organisés en dossiers, c'est-à-dire qu'un fichier *.txt* correspond à une page du roman. Il a donc fallu les regrouper pour obtenir un seul fichier *.txt* par roman.

2. Lien du logiciel : <https://calibre-ebook.com/fr/about>, site consulté le 18 juin 2026.

convertir au format *.txt*. Pour les textes au format *.pdf*, j'ai utilisé le logiciel *Adobe Acrobat Pro* afin de les convertir au format *.txt*. Pour les textes au format *.txt*, j'ai utilisé un script Python³ pour regrouper les fichiers en un seul fichier par roman.

La grande majorité de mes romans étaient au format *.epub*. Après leur conversion au format *.txt*, j'ai donc utilisé un script Python⁴ pour nettoyer les textes. Ce script supprime les caractères spéciaux, les notes de bas de page, les chapitres et les prologues. Il supprime également les lignes vides et les espaces en trop. Le script est basé sur des expressions régulières pour identifier les éléments à supprimer.

Pour ce qui est du choix des éléments à supprimer, j'ai fait le choix de supprimer les chapitres, car ils ne sont pas représentatifs du style d'écriture de l'auteur. De plus, comme nous l'avons vu dans le chapitre 2, j'ai passé un détecteur de motifs sur les textes afin d'identifier les motifs récurrents. J'ai donc gardé uniquement le corps du texte pour l'analyse. Ce choix se justifie également par la volonté d'obtenir une normalisation entre les textes⁵ (une ligne est égal à une phrase), ce choix peut être mis en opposition avec le choix de garder la distinction entre les différents chapitres du roman mais je me défend en prenant en compte que certains romans ne sont pas découpés en chapitres. Les différents romans sont soit découpés en partie (exemple : Partie I, Partie II, etc.), soit en chapitres (exemple : Chapitre I, Chapitre II, etc.), soit avec une combinaison des deux (exemple : Partie I, Chapitre I, Chapitre II, Partie II, Chapitre III, etc.). Ou pour finir, le titre du chapitre est écrit en majuscules, avec des chiffres romains, ou sans chiffres romains. Il aurait donc fallu faire des ajustements à chaque fois pour identifier les chapitres. De plus, certains romans résultaient de l'assemblage de plusieurs fichiers *.txt*. Dans ces cas, la séparation entre les chapitres, initialement présente dans la structure HTML du roman, n'était plus conservée.

2.3 Création de la base de données

Après avoir nettoyé les textes, il a fallu créer une base de données pour stocker les informations relatives aux romans. J'ai choisi d'utiliser le système de gestion de base de données relationnelle *MySQL*, car il permet d'organiser les données sous forme de tables et de conserver des relations claires entre les auteurs, les romans et les unités textuelles extraites.

Je vais donc présenter la structure de cette base de données ainsi que les différentes tables qui la composent. Chaque table a un rôle précis : certaines servent à stocker les

3. Le script est disponible en annexe.

4. Le script est disponible en annexe. Il faut préciser que je n'ai pas utilisé un seul script, mais plusieurs. Il s'agit donc d'un script général. Il y a eu énormément de modifications internes, notamment pour les chapitres qui sont soit en majuscules, avec chiffres romains, ou sans chiffres romains. Il a donc fallu faire des ajustements à chaque fois.

5. certains textes ne disposant pas de

informations bibliographiques, tandis que d'autres permettent de conserver les textes, les segments ou encore les phrases extraites pour l'analyse.

J'ai choisi de présenter ce code directement dans le corps du mémoire⁶ et non uniquement en annexe, afin de rendre plus claire la manière dont les données ont été organisées avant l'analyse.

Ce code permet de créer la base de données utilisée pour stocker les romans du corpus ainsi que les informations nécessaires à leur analyse. La base, nommée **romans_nlp**, est d'abord créée puis sélectionnée afin que toutes les tables suivantes y soient enregistrées.

La première table, **auteurs**, sert à stocker les informations relatives aux auteurs. Chaque auteur reçoit un identifiant unique, auquel sont associés son nom et, lorsque l'information est disponible, son prénom. Cette table est ensuite complétée par deux colonnes supplémentaires, **date_naissance** et **date_mort**, afin d'enrichir la description des auteurs et de permettre d'éventuelles analyses chronologiques.

La table **romans** contient les informations principales sur les œuvres du corpus. Elle associe à chaque roman un identifiant unique, un titre, une année de publication ainsi que le texte brut du roman. Le choix du type **LONGTEXT** pour le champ **texte_brut** permet de stocker des textes longs, ce qui est nécessaire dans le cas de romans complets.

La table **auteurs_romans** permet de faire le lien entre les auteurs et les romans. Elle sert à gérer une relation de type plusieurs-à-plusieurs : un auteur peut être associé à plusieurs romans, et un roman peut éventuellement être associé à plusieurs auteurs. Les clés étrangères **id_auteur** et **id_roman** permettent de relier cette table aux tables **auteurs** et **romans**.

La table **segments** sert à stocker les segments extraits des romans. Chaque segment est rattaché à un roman grâce à la clé étrangère **id_roman**. Le champ **ordre_segment** permet de conserver l'ordre d'apparition des segments dans le texte d'origine. Cela est important, car même si le texte est découpé pour les traitements, il reste possible de retrouver sa progression initiale.

Enfin, la table **phrase_roman** permet de stocker les phrases extraites des romans. Chaque phrase est associée au roman dont elle provient, à son ordre d'apparition, à son contenu textuel et au motif qui a permis son extraction. Ce dernier champ est important, car il permet de garder une trace de la méthode utilisée pour sélectionner les phrases et de relier chaque extraction à un critère précis.

L'ensemble de cette structure permet donc de conserver à la fois les textes complets, leurs découpages en segments, les phrases extraites et les informations bibliographiques liées aux auteurs et aux œuvres. Elle constitue ainsi une base organisée pour les traitements de fouille de texte et d'analyse automatique du corpus.

6. Je précise également que tous les codes utilisés pour la réalisation de ce mémoire sont disponibles sur mon GitHub.

```

1 CREATE DATABASE romans_nlp;
2 USE romans_nlp;
3
4 -- Creation des tables pour la base de donnees des romans et des auteurs
5 CREATE TABLE auteurs (
6     id_auteur INT PRIMARY KEY AUTO_INCREMENT,
7     nom VARCHAR(100) NOT NULL,
8     prenom VARCHAR(100)
9 );
10
11 -- Table pour stocker les romans, avec leur titre et leur annee de publication
12 CREATE TABLE romans (
13     id_roman INT PRIMARY KEY AUTO_INCREMENT,
14     titre VARCHAR(255) NOT NULL,
15     annee_publication INT,
16     texte_brut LONGTEXT
17 );
18
19 -- Table d'association pour gerer la relation plusieurs-a-plusieurs entre auteurs et romans
20 CREATE TABLE auteurs_romans (
21     id_auteur INT NOT NULL,
22     id_roman INT NOT NULL,
23     PRIMARY KEY (id_auteur, id_roman),
24     FOREIGN KEY (id_auteur) REFERENCES auteurs(id_auteur),
25     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
26 );
27
28 -- Table pour stocker les segments extraits des romans, avec leur ordre de segmentation
29 CREATE TABLE segments (
30     id_segment INT PRIMARY KEY AUTO_INCREMENT,
31     id_roman INT NOT NULL,
32     ordre_segment INT NOT NULL,
33     texte_segment LONGTEXT NOT NULL,
34     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
35 );
36
37 /*
38  Apres reflexion, il est egalement possible d'ajouter les dates
39  de naissance et de mort des auteurs afin d'enrichir la base de donnees.
40  */
41 ALTER TABLE auteurs
42 ADD date_naissance INT;
43
44 ALTER TABLE auteurs
45 ADD date_mort INT;
46
47 -- Table pour stocker les phrases extraites des romans, avec leur motif d'extraction
48 CREATE TABLE phrase_roman (
49     id_phrase INT PRIMARY KEY AUTO_INCREMENT,
50     id_roman INT NOT NULL,
51     ordre_phrase INT NOT NULL,
52     texte_phrase TEXT NOT NULL,
53     motif_phrase TEXT NOT NULL,
54     FOREIGN KEY (id_roman) REFERENCES romans(id_roman)
55 );

```

Listing 1 – Création de la base de données romans_nlp

2.4 Création des informations pour la base de données

Après avoir créé les tables nécessaires pour stocker les informations sur les auteurs, les romans et les relations entre eux, il est temps d'insérer les données relatives aux frères Goncourt et à leurs œuvres. Le code suivant présente donc l'insertion des auteurs, des romans et des relations entre ces deux tables.

```
1  /*
2  Insertion des freres Goncourt.
3  */
4  INSERT INTO auteurs (nom, prenom)
5  VALUES
6      ('de Goncourt', 'Edmond'),
7      ('de Goncourt', 'Jules');
8  /*
9  Insertion des romans des freres Goncourt
10 */
11 INSERT INTO romans (titre, annee_publication)
12 VALUES
13     ('Charles Demailly', 1860),
14     ('Soeur Philomene', 1861),
15     ('Renee Mauperin', 1864),
16     ('Germinie Lacerteux', 1865),
17     ('Manette Salomon', 1867),
18     ('Madame Gervaisais', 1869),
19     ('La Fille Elisa', 1877),
20     ('Freres Zemganno', 1879),
21     ('La Faustin', 1882),
22     ('Cherie', 1884);
23 /*
24 Insertion des relations entre les auteurs et les romans.
25 Les six premiers romans sont associes aux deux freres Goncourt.
26 Les romans suivants sont associes uniquement a Edmond de Goncourt.
27 */
28 INSERT INTO auteurs_romans (id_auteur, id_roman)
29 VALUES
30     (1,1), (2,1),
31     (1,2), (2,2),
32     (1,3), (2,3),
33     (1,4), (2,4),
34     (1,5), (2,5),
35     (1,6), (2,6),
36     (1,7),
37     (1,8),
38     (1,9),
39     (1,10);
40 -- Mise a jour des dates de naissance et de mort de Jules de Goncourt.
41 UPDATE auteurs
42 SET date_naissance = 1830,
43     date_mort = 1870
44 WHERE id_auteur = 2;
45
46 -- Mise a jour des dates de naissance et de mort d'Edmond de Goncourt.
47 UPDATE auteurs
48 SET date_naissance = 1822,
```

```
49     date_mort = 1896
50 WHERE id_auteur = 1;
51
```

Ce code permet d'insérer dans la base de données les informations relatives aux frères Goncourt et à leurs romans. Dans un premier temps, les deux auteurs sont ajoutés dans la table **auteurs**. Ils reçoivent chacun un identifiant, qui permettra ensuite de les relier aux œuvres présentes dans la base.

La deuxième partie du code insère les romans des frères Goncourt dans la table **romans**. Chaque œuvre est associée à son titre et à son année de publication. Cette étape permet donc de constituer une partie du corpus à partir des romans retenus pour l'analyse.

Ensuite, la table **auteurs_romans** est utilisée pour associer les auteurs aux romans. Cette table est importante, car elle permet de gérer le cas particulier des œuvres écrites à deux mains. Les six premiers romans sont associés à Edmond et Jules de Goncourt, tandis que les romans publiés après la mort de Jules sont associés uniquement à Edmond. Cela permet de conserver une information plus précise sur l'attribution des œuvres.

Enfin, les deux dernières requêtes mettent à jour les dates de naissance et de mort des auteurs. Ces informations biographiques ne sont pas directement nécessaires pour stocker les textes, mais elles permettent d'enrichir la base de données. Elles peuvent aussi être utiles par la suite si l'on souhaite croiser les résultats de l'analyse avec des éléments chronologiques ou biographiques.

Ce passage sert donc à remplir une première partie de la base de données avec les auteurs, les romans et les relations entre eux. Il montre aussi l'intérêt de séparer les informations dans plusieurs tables : les auteurs sont stockés d'un côté, les romans de l'autre, et la relation entre les deux est conservée dans une table spécifique.

Il faut maintenant ajouter les romans dans la base de données, il peut y avoir plusieurs façons de le faire,

