

Université Lyon 2, Lyon 3, ENSIB, ENS Lyon

Origine, circularité et transformation des motifs naturalistes

Mémoire présenté par Morgan RICHARD

Année universitaire 2025–2026

Remerciements

Je tiens à remercier...

Résumé

Ce mémoire porte sur...

Table des matières

Remerciements	i
Résumé	ii
Introduction	1
1 Topic modeling sur les romans d'Émile Zola	2
1.1 Présentation du corpus	2
2 Nettoyage des romans et insertion de ces derniers dans la base de données	3
2.1 Reflexion sur le stockage des données	3
2.2 Nettoyage des textes	3

Introduction

Chapitre 1

Topic modeling sur les romans d'Émile Zola

1.1 Présentation du corpus

Chapitre 2

Nettoyage des romans et insertion de ces derniers dans la basse de données

2.1 Reflexion sur le stockage des données

Après avoir récupéré un nombre conséquent de romans naturalistes et non naturaliste, il a fallu réfléchir à un moyen de les stocker quelque part. Pour cela, j'ai réfléchi à plusieurs idées pour procéder. Le choix c'est porté sur une base de données SQL avec comme interface PHP admin. Cette base de données à d'abord été remplie en local pour effectuer des tests et ensuite, une fois que tout fonctionnait correctement, j'ai pu extraire un fichier *Dumps* et l'importer dans PHP Admin.

2.2 Nettoyage des textes

Après avoir réfléchi à comment stocker les romans, il a fallu réfléchir à un moyen de les nettoyer. En effet, les romans contiennent beaucoup de caractères spéciaux qui ne sont pas utiles pour l'analyse, notamment les caractères de mise en forme, pagination, les notes de bas de pages, les chapitres ainsi que prologues (en effet les prologues sont souvent des textes qui ne sont pas écrit par l'auteur du roman et qui ne sont donc pas représentatif de son style d'écriture).

Les romans naturalistes et non naturalistes sont issus de type de données différents. Il y a 3 groupes de format de données : les romans en format *.epub*, les romans en format *.pdf* et les romans en format *.txt*¹.

Pour ce qui est des textes en format *.epub*, j'ai utilisé le logiciel *Calibre*² pour les

1. ici les tetxes en format *.txt* sont des en dossier, c'est à dire qu'un fichier *.txt* correspond a une page du roman, il a donc fallut les regrouper pour obtenir un seul fichier *.txt* par roman

2. le lien du lien du locigiciel <https://calibre-ebook.com/fr/about>, site consulté le 18 juin 2026

convertir en format *.txt*. Pour les textes en format *.pdf*, j'ai utilisé le logiciel *Adobe Acrobat Pro* pour les convertir en format *.txt*. Pour les textes en format *.txt*, j'ai utilisé un script python³ pour regrouper les fichiers en un seul fichier par roman.

La grande majorité de mes romans étaient en format *.epub* après leurs conversions en format *.txt*, j'ai donc utilisé un script python⁴ pour nettoyer les textes. Ce script supprime les caractères spéciaux, les notes de bas de pages, les chapitres et les prologues. Il supprime également les lignes vides et les espaces en trop. Le script est basé sur des expressions régulières pour identifier les éléments à supprimer.

Pour ce qui est du choix des choses à supprimer, j'ai fait le choix de supprimer les chapitres car ils ne sont pas représentatif du style d'écriture de l'auteur. De plus comme nous l'avons vu dans le chapitre 2, j'ai passé un détecteur de motif sur les textes pour identifier les motifs récurrents dans les textes. J'ai donc gardé que le corps de texte pour l'analyse. Ce choix est justifié aussi par le fait d'avoir une normalisation entre les textes⁵.

3. Le script est disponible en annexe

4. Le script est disponible en annexe. Il faut préciser que je n'ai pas utilisé qu'un script mais plusieurs ce sera un script général, il y a eu énormément de modifications interne pour ces derniers notamment pour les chapitres qui sont soit en majuscule, avec chiffre romains ou sans chiffre romains etc. Il a donc fallu faire des ajustements à chaque fois.

5.

Annexe technique : code